

ExamBoost Togo

Cours Théorique Complet

Apprentissage Adaptatif · Répétition Espacée · Théorie de la Réponse aux
Items
Modèles ML · Stratégie de Collecte des Données

Module 1 — Fondements Cognitifs de l'Apprentissage

Module 2 — Répétition Espacée (SRS) et Algorithme SM-2

Module 3 — Théorie de la Réponse aux Items (IRT)

Module 4 — Traçage de la Connaissance (BKT)

Module 5 — Modèles ML et Entraînement

Module 6 — Stratégie de Collecte des Données

Préparé par l'équipe SmartFarm Togo / AIMS Ghana

Mai 2025 — Version complète avec exercices corrigés

Niveau : Intermédiaire — pas de prérequis en ML

Format : Cours + Formules + Exemples + Exercices corrigés

Objectif : Maîtriser les fondements théoriques d'ExamBoost Togo

Ce cours est la base théorique du projet ExamBoost Togo. Il couvre les algorithmes, modèles, et la stratégie de données nécessaires pour construire une plateforme de préparation aux examens intelligente et performante.

Table des matières

Introduction Générale	3
1 Module 1 — Fondements Cognitifs de l'Apprentissage	4
1.1 La Courbe de l'Oubli d'Ebbinghaus	4
1.1.1 La formule mathématique de l'oubli	4
1.1.2 Exemple concret	4
1.2 L'Effet de l'Espacement — Pourquoi réviser plusieurs fois . . .	5
1.3 Types de Mémoire et Implications Pédagogiques	6
2 Module 2 — Répétition Espacée : L'Algorithme SM-2	7
2.1 Principe Général	7
2.2 Variables de l'Algorithme SM-2	7
2.3 Grille de Qualité des Réponses	8
2.4 Les Trois Formules Fondamentales de SM-2	8
2.5 Analyse Détaillée de la Formule du Facteur d'Aisance	8
2.6 Simulation Pas-à-Pas de SM-2	9
2.7 Limites de SM-2 et Introduction à FSRS	10
3 Module 3 — Théorie de la Réponse aux Items (IRT)	11
3.1 Qu'est-ce que l'IRT?	11
3.2 Contraste avec la Théorie Classique des Tests (TCT)	11
3.3 La Famille de Modèles IRT	11
3.4 Le Modèle 3PL — Formule Complète et Paramètres	12
3.5 Interprétation Graphique — La Courbe Caractéristique d'Item (CCI)	12
3.6 Exemples Numériques IRT	13
3.7 Comment Estimer les Paramètres IRT en Pratique	14
4 Module 4 — Traçage de la Connaissance : Le Modèle BKT	15
4.1 Motivation : Pourquoi IRT ne suffit pas	15
4.2 Définition et Paramètres du BKT	15
4.3 Les Équations de Mise à Jour du BKT	16
4.4 Exemple Numérique Complet — BKT	16
5 Module 5 — Modèles ML : Inventaire, Rôles et Entraînement	18
5.1 Vue d'Ensemble des Modèles ML du Projet	18
5.2 Modèle 1 — IRT : Calibration des Questions	18
5.2.1 Rôle dans ExamBoost	18
5.2.2 Données nécessaires	18
5.2.3 Procédure d'entraînement	18
5.2.4 Choix du modèle : 1PL, 2PL ou 3PL?	19
5.3 Modèle 2 — BKT : Traçage de la Maîtrise	19
5.3.1 Rôle dans ExamBoost	19
5.3.2 Entraînement du BKT	19

5.3.3 Variante : Deep Knowledge Tracing (DKT)	20
5.4 Modèle 3 — Prédiction du Score à l'Examen	20
5.4.1 Rôle dans ExamBoost	20
5.4.2 Features (variables d'entrée)	21
5.4.3 Algorithmes candidats	21
5.4.4 Entraînement du modèle de prédiction	22
5.5 Modèle 4 — Détection des Élèves à Risque de Décrochage . . .	22
5.6 Récapitulatif : Modèles, Données et Performances Attendues .	23
6 Module 6 — Stratégie Complète de Collecte des Données	24
6.1 Vue d'Ensemble : Les Trois Couches de Données	24
6.2 Couche 1 : Données Pédagogiques Disponibles en Ligne	24
6.2.1 Sources identifiées pour le BEPC, BAC 1 et BAC 2 (Togo)	24
6.2.2 Couverture par Matière : Inventaire Estimé	26
6.3 Processus de Numérisation : Du PDF au QCM Structuré	26
6.3.1 Structure de la Base de Données Questions	27
6.4 Couche 2 : Données du Programme MEPST	28
6.4.1 Contenu à obtenir	28
6.4.2 Stratégie d'accès	28
6.5 Couche 3 : Données à Produire — Les Examens Blancs	28
6.5.1 Pourquoi les examens blancs sont critiques	28
6.5.2 Stratégie de génération de nouvelles questions	28
6.5.3 Stratégie de collecte des données comportementales in- app	29
6.6 Plan de Collecte : Calendrier et Responsabilités	30
Conclusion	31

Introduction Générale

Ce cours te donnera une compréhension solide et complète de tous les fondements théoriques qui font fonctionner ExamBoost Togo. Tu n'as pas besoin d'être expert en éducation ni en intelligence artificielle pour le lire : chaque concept est expliqué depuis les bases, avec des formules détaillées, des exemples concrets tirés du contexte togolais, et des exercices corrigés pour vérifier ta compréhension.

Carte des modules

- **Modules 1-2** : Pourquoi les élèves oublient et comment la répétition espacée combat l'oubli
- **Module 3** : Comment mesurer la difficulté d'une question et le niveau d'un élève (IRT)
- **Module 4** : Comment suivre en temps réel la maîtrise d'une compétence (BKT)
- **Module 5** : Quels modèles ML entraîner, avec quelles données, et comment choisir le meilleur
- **Module 6** : Comment trouver toutes les données disponibles pour le BEPC et le BAC

1 Module 1 — Fondements Cognitifs de l'Apprentissage

1.1 La Courbe de l'Oubli d'Ebbinghaus

Définition — La courbe de l'oubli

En 1885, le psychologue Hermann Ebbinghaus a mené des expériences sur lui-même pour mesurer à quelle vitesse la mémoire décline après une seule séance d'apprentissage. Il a découvert que l'oubli suit une **courbe exponentielle décroissante**.

1.1.1 La formule mathématique de l'oubli

La **rétenion** $R(t)$ à l'instant t (en jours) après un apprentissage est modélisée par :

Formule d'Ebbinghaus

$$R(t) = e^{-t/S}$$

où :

- $R(t) \in [0, 1]$: fraction de l'information encore mémorisée à l'instant t
- t : temps écoulé depuis le dernier apprentissage (en jours)
- S : **stabilité de la mémoire**, propre à chaque individu et à chaque contenu (plus S est grand, plus l'oubli est lent)

1.1.2 Exemple concret

Amina, élève de 3^{ème} à Lomé, apprend la règle de calcul des angles alternes-internes. Sa stabilité pour ce concept est $S = 3$ jours.

- **Immédiatement après le cours** : $R(0) = e^0 = 1 \Rightarrow 100\%$ retenu
- **Le lendemain** ($t = 1$) : $R(1) = e^{-1/3} \approx 0,72 \Rightarrow 72\%$ retenu
- **3 jours après** : $R(3) = e^{-1} \approx 0,37 \Rightarrow 37\%$ retenu
- **7 jours après** : $R(7) = e^{-7/3} \approx 0,10 \Rightarrow$ seulement 10% retenu

Conclusion : Sans révision, Amina a oublié 90% de ce contenu en une semaine.

1.2 L'Effet de l'Espacement — Pourquoi réviser plusieurs fois

Chaque fois qu'un élève revoit une information **avant de l'avoir complètement oubliée**, deux choses se produisent :

1. La rétention R est remise à 1 (ou proche de 1)
2. La **stabilité** S augmente — le prochain oubli sera plus lent

Après k révisions espacées, la stabilité suit approximativement :

$$S_k \approx S_0 \times c^k$$

où $c > 1$ est un facteur de consolidation (typiquement $c \approx 2$ à 3 selon les recherches).

Exercice 1.1 — Courbe de l'oubli

Kofi, élève de Terminale à Kara, apprend une formule de chimie organique. Sa stabilité initiale est $S_0 = 2$ jours. Le facteur de consolidation est $c = 2,5$.

- a) Quelle est sa rétention 5 jours après le premier apprentissage, sans aucune révision ?
- b) Il révise le jour 2 (donc $R(2) \approx 0,37$ reste en mémoire, mais la stabilité passe à $S_1 = S_0 \times c = 5$ jours). Quelle est sa rétention 10 jours après cette première révision ?
- c) Pourquoi vaut-il mieux réviser le jour 2 plutôt que le jour 10 ?

Correction de l'Exercice 1.1

- a) $R(5) = e^{-5/2} = e^{-2,5} \approx 0,082$. Kofi n'a retenu que **8,2%**. C'est catastrophique : après 5 jours sans révision, la formule est pratiquement perdue.
- b) Après la révision au jour 2, $S_1 = 2 \times 2,5 = 5$ jours. Dix jours après cette révision : $R(10) = e^{-10/5} = e^{-2} \approx 0,135$. Kofi retient encore **13,5%**. C'est encore peu, mais **bien mieux** que sans aucune révision.
- c) Réviser au jour 2 (quand $R \approx 37\%$) renforce la mémoire **alors qu'il reste encore quelque chose à consolider**. Réviser au jour 10 ($R < 1\%$) revient à **réapprendre de zéro**, sans bénéfice sur la stabilité. L'espacement optimal est de réviser juste avant que l'oubli soit complet — c'est exactement ce que fait l'algorithme SM-2.

1.3 Types de Mémoire et Implications Pédagogiques

Type	Durée	Capacité	Renforcement
Sensorielle	0,5 à 3 secondes	Illimitée	Attention
Court terme (MCT)	20 à 30 secondes	7 ± 2 éléments	Répétition immédiate
Long terme (MLT)	Des années	Pratiquement illimitée	Espacement + sens

Pour ExamBoost : Notre objectif est de transférer les connaissances du BEPC et du BAC de la mémoire court terme (séance de cours) vers la **mémoire long terme**. La répétition espacée est le mécanisme scientifique le plus efficace connu pour accomplir ce transfert.

2 Module 2 — Répétition Espacée : L'Algorithme SM-2

2.1 Principe Général

Définition — Système de Répétition Espacée (SRS)

Un **Système de Répétition Espacée** (Spaced Repetition System, SRS) est un algorithme qui planifie automatiquement les révisions de chaque élément d'apprentissage au moment **optimal** : juste avant que l'élève l'oublie. Si l'élève répond correctement, le prochain rappel est espacé plus loin dans le temps. S'il échoue, le rappel est ramené à court terme.

L'algorithme SM-2, développé par Piotr Wozniak en 1987 et utilisé par Anki (plus de 10 millions d'utilisateurs), est le SRS le plus documenté et le plus prouvé scientifiquement.

2.2 Variables de l'Algorithme SM-2

Variable	Signification	Valeur initiale / Contrainte
n	Numéro de la répétition (compteur)	$n = 0$ pour une carte neuve
$I(n)$	Intervalle en jours avant la prochaine révision	$I(1) = 1, I(2) = 6$
EF	Facteur d'aisance (Easiness Factor)	Initialisé à 2,5 ; $EF \geq 1,3$
q	Qualité de la réponse (évaluation élève)	Entier de 0 à 5

2.3 Grille de Qualité des Réponses

Score q	Signification	Succès ?
5	Réponse parfaite, sans hésitation	Oui
4	Réponse correcte avec une légère hésitation	Oui
3	Réponse correcte mais difficile à retrouver	Oui (minimum)
2	Mauvaise réponse ; la bonne semblait facile	Non
1	Mauvaise réponse ; la bonne est revenue en mémoire après	Non
0	Blackout complet — aucun souvenir	Non

2.4 Les Trois Formules Fondamentales de SM-2

SM-2 — Les 3 Formules

Formule 1 — Calcul de l'intervalle suivant :

$$I(1) = 1 \text{ jour}, \quad I(2) = 6 \text{ jours}, \quad I(n) = \lfloor I(n-1) \times EF \rfloor \quad \text{pour } n > 2$$

Formule 2 — Mise à jour du facteur d'aisance :

$$EF' = EF + (0,1 - (5 - q) \times (0,08 + (5 - q) \times 0,02))$$

avec la contrainte : si $EF' < 1,3$, alors $EF' \leftarrow 1,3$.

Formule 3 — Règle en cas d'échec ($q < 3$) :

$$n \leftarrow 0, \quad I \leftarrow 1 \text{ jour} \quad (\text{la carte recommence depuis le début})$$

Remarque : l'EF est quand même mis à jour (il diminue), même en cas d'échec.

2.5 Analyse Détaillée de la Formule du Facteur d'Aisance

La formule $EF' = EF + (0,1 - (5 - q)(0,08 + (5 - q) \times 0,02))$ peut sembler complexe. Développons-la pour chaque valeur de q :

Score q	Variation de EF	Numérique	Interprétation
5	+0,10	$EF' = EF + 0,10$	Très facile : les intervalles s'allongent vite
4	0 (neutre)	$EF' = EF$	Correct : le rythme ne change pas
3	-0,14	$EF' = EF - 0,14$	Difficile : révisions légèrement plus fréquentes
2	-0,46	$EF' = EF - 0,46$	Erreur : révisions nettement plus fréquentes
1	-0,96	$EF' = EF - 0,96$	Grosse erreur : presque au minimum
0	-1,64	$EF' = EF - 1,64$ (mais $\geq 1,3$)	Blackout : plancher obligatoire

Interprétation : Un $EF = 2,5$ (valeur initiale) donne des intervalles qui doublent à chaque révision réussie ($1 \rightarrow 6 \rightarrow 15 \rightarrow 37 \rightarrow 92$ jours...). Un $EF = 1,3$ (plancher) donne des intervalles qui croissent lentement, signalant une notion très difficile.

2.6 Simulation Pas-à-Pas de SM-2

Situation : Kofi révise la définition du «théorème de Pythagore». EF initial = 2,5.

Révision	q	EF avant	EF après	I (jours)	Prochaine date
1	3	2,50	2,36	1	Demain
2	4	2,36	2,36	6	Dans 6 jours
3	5	2,36	2,46	14	Dans 14 jours
4	2	2,46	2,00	1	Retour à 1 jour (échec)
5	4	2,00	2,00	6	Dans 6 jours (recommence)
6	5	2,00	2,10	12	Dans 12 jours

Remarque sur la révision 4 : Kofi a obtenu $q = 2$ (erreur). L'intervalle revient à 1 jour et n est remis à 0. L'EF chute de 2,46 à 2,00 : le système a «appris» que cette notion est difficile pour Kofi et planifiera des révisions plus fréquentes.

Exercice 2.1 — Calcul SM-2 à la main

Amina révise le concept de «Mitose» pour la série D du BAC. Ses réponses successives sont $q = 4, 5, 3, 5$. Partant de $EF_0 = 2,5$:

- Calculer EF après chaque révision.
- Calculer les intervalles $I(1), I(2), I(3), I(4)$.
- Si la 4^{ème} révision a lieu le **1er septembre**, à quelle date est planifiée la 5^{ème} ?

Correction de l'Exercice 2.1

a) Calcul des EF successifs :

Révision 1 ($q = 4$) : $EF_1 = 2,5 + (0,1 - 1 \times (0,08 + 1 \times 0,02)) = 2,5 + 0 = \mathbf{2,50}$

Révision 2 ($q = 5$) : $EF_2 = 2,5 + 0,1 = \mathbf{2,60}$

Révision 3 ($q = 3$) : $EF_3 = 2,6 + (0,1 - 2 \times (0,08 + 2 \times 0,02)) = 2,6 + (0,1 - 2 \times 0,12) = 2,6 - 0,14 = \mathbf{2,46}$

Révision 4 ($q = 5$) : $EF_4 = 2,46 + 0,1 = \mathbf{2,56}$

b) Calcul des intervalles :

$I(1) = 1$ jour ; $I(2) = 6$ jours ; $I(3) = \lfloor 6 \times 2,46 \rfloor = \lfloor 14,76 \rfloor = 14$ jours ; $I(4) = \lfloor 14 \times 2,56 \rfloor = \lfloor 35,84 \rfloor = 35$ jours.

c) Date de la 5^{ème} révision :

La 4^{ème} révision a eu lieu le 1^{er} septembre. L'intervalle suivant est $I(4) = 35$ jours. La prochaine révision est donc planifiée le **1^{er} septembre + 35 jours = 6 octobre**.

2.7 Limites de SM-2 et Introduction à FSRS

SM-2 présente quelques limites connues :

- L'EF initial de 2,5 est le même pour tous les élèves et toutes les notions : pas de personnalisation de départ
- La note q (0-5) est subjective : des élèves noteraient $q = 4$ quand d'autres noteraient $q = 3$ pour la même réponse
- SM-2 ne modélise pas la «stabilité de la mémoire» au sens d'Ebbinghaus : il n'a pas de notion de courbe d'oubli explicite

Alternative moderne : FSRS (Free Spaced Repetition Scheduler), développé en 2022, modélise directement la stabilité S et la récupérabilité R . Ses benchmarks montrent une amélioration de 20-40 % sur les prédictions d'oubli par rapport à SM-2. **Pour ExamBoost Togo :** Commencer avec SM-2 (simple, prouvé) et migrer vers FSRS dès que la base utilisateurs atteint 10 000 révisions.

3 Module 3 — Théorie de la Réponse aux Items (IRT)

3.1 Qu'est-ce que l'IRT ?

Définition — Théorie de la Réponse aux Items (IRT)

L'IRT (Item Response Theory) est une famille de modèles statistiques qui modélise la **probabilité qu'un élève réponde correctement à une question**, en fonction de deux types de paramètres :

- Les **paramètres de l'item** (la question) : difficulté, discrimination, chance
- Le **paramètre de l'élève** : son niveau de compétence θ (theta)

L'IRT est utilisée dans des tests à fort enjeu comme le GRE, le GMAT, le TOEFL, et par Duolingo pour calibrer ses questions.

3.2 Contraste avec la Théorie Classique des Tests (TCT)

Aspect	Théorie Classique (TCT)	Théorie IRT
Mesure de la difficulté	Proportion d'élèves ayant répondu juste	Paramètre b indépendant du groupe
Mesure du niveau	Score brut (sur 20)	θ sur une échelle continue
Dépendance au groupe	Forte (une question «difficile» pour des bons élèves peut être «facile» pour une autre population)	Faible : les paramètres sont invariants
Adaptativité	Impossible	Possible : CAT (Computerized Adaptive Testing)

3.3 La Famille de Modèles IRT

L'IRT comporte trois modèles principaux, selon le nombre de paramètres considérés :

Modèle	Paramètres	Quand l'utiliser	Formule
1PL (Rasch)	Difficulté b seulement	Tests très homogènes	$P(\theta) = \frac{1}{1 + e^{-(\theta-b)}}$
2PL	Difficulté b + Discrimination a	Examens nationaux	$P(\theta) = \frac{1}{1 + e^{-a(\theta-b)}}$
3PL	$b + a +$ Chance c	QCM (risque de deviner)	Voir formule complète ci-dessous

3.4 Le Modèle 3PL — Formule Complète et Paramètres

Formule du modèle IRT 3PL

$$P(X_{ij} = 1 \mid \theta_i, a_j, b_j, c_j) = c_j + (1 - c_j) \cdot \frac{1}{1 + e^{-1,7 a_j (\theta_i - b_j)}}$$

où :

- $P(\cdot)$: probabilité que l'élève i réponde correctement à la question j
- θ_i : **niveau de compétence** de l'élève i (variable latente, échelle $\sim \mathcal{N}(0, 1)$)
- $a_j > 0$: **paramètre de discrimination** de la question j (pente de la courbe ; valeur typique : $0,5 < a < 2,5$)
- b_j : **paramètre de difficulté** de la question j (point d'inflexion ; valeur typique : $-3 < b < 3$)
- $c_j \in [0, 1)$: **paramètre de chance** (guessing) (valeur typique pour un QCM à 4 choix : $c \approx 0,25$)
- 1,7 : constante de mise à l'échelle logistique (approximation de la distribution normale)

3.5 Interprétation Graphique — La Courbe Caractéristique d'Item (CCI)

Chaque question j possède une **Courbe Caractéristique d'Item** (Item Characteristic Curve, ICC) : c'est la représentation graphique de $P(\theta)$ en fonction de θ .

Propriétés de la courbe :

- Elle est en forme de **S** (sigmoïde)
- Son **point d'inflexion** se situe à $\theta = b$ (niveau pour lequel $P \approx \frac{1+c}{2}$)
- Sa **pente maximale** est proportionnelle à a : plus a est grand, plus la

courbe est raide

- Son **asymptote inférieure** est c : même un élève très faible a une probabilité c de répondre juste (chance)

3.6 Exemples Numériques IRT

Question 1 (BEPC, Mathématiques) : «Calculer l'aire d'un triangle de base 6 cm et hauteur 4 cm.» Paramètres estimés : $a = 1,2$, $b = -0,5$, $c = 0$ (question ouverte, pas de chance).

Question 2 (BAC série C, Physique) : «Parmi les propositions suivantes, laquelle définit correctement la vitesse instantanée ?» (QCM à 4 choix) Paramètres estimés : $a = 1,8$, $b = 0,8$, $c = 0,25$.

Calculons $P(\theta = 0)$ pour les deux questions (élève de niveau moyen) :

Question 1 :

$$P = 0 + 1 \cdot \frac{1}{1 + e^{-1,7 \times 1,2 \times (0 - (-0,5))}} = \frac{1}{1 + e^{-1,02}} = \frac{1}{1 + 0,360} \approx \mathbf{0,735}$$

Un élève moyen ($\theta = 0$) a 73,5% de chances de réussir cette question : elle est relativement accessible.

Question 2 :

$$P = 0,25 + 0,75 \cdot \frac{1}{1 + e^{-1,7 \times 1,8 \times (0 - 0,8)}} = 0,25 + 0,75 \cdot \frac{1}{1 + e^{2,448}} \approx 0,25 + 0,75 \times 0,080 \approx \mathbf{0,310}$$

Un élève moyen n'a que 31% de chances de réussir cette question : elle est difficile.

Exercice 3.1 — Calcul de probabilité IRT

Une question de Français (BEPC) sur l'analyse de texte a les paramètres suivants : $a = 1,0$, $b = 0,2$, $c = 0$.

- Calculer la probabilité de réussite pour un élève faible ($\theta = -1$).
- Calculer la probabilité de réussite pour un élève moyen ($\theta = 0$).
- Calculer la probabilité de réussite pour un excellent élève ($\theta = 2$).
- A quel niveau θ^* la probabilité de réussite est-elle exactement de 50% ?

Correction de l'Exercice 3.1

On utilise le modèle 1PL (car $c = 0$) : $P(\theta) = \frac{1}{1 + e^{-1,7 \times 1,0 \times (\theta - 0,2)}}$

a) $\theta = -1$: $P = \frac{1}{1 + e^{-1,7(-1-0,2)}} = \frac{1}{1 + e^{2,04}} = \frac{1}{1 + 7,69} \approx \mathbf{0,115}$ soit 11,5%.

b) $\theta = 0$: $P = \frac{1}{1 + e^{-1,7(0-0,2)}} = \frac{1}{1 + e^{0,34}} = \frac{1}{1 + 1,404} \approx \mathbf{0,416}$ soit 41,6%.

c) $\theta = 2$: $P = \frac{1}{1 + e^{-1,7(2-0,2)}} = \frac{1}{1 + e^{-3,06}} = \frac{1}{1 + 0,047} \approx \mathbf{0,955}$ soit 95,5%.

d) $P = 0,5$ quand l'exponentielle vaut 1, i.e., $e^{-1,7(\theta^*-0,2)} = 1 \Rightarrow \theta^* = b = \mathbf{0,2}$. Le paramètre de difficulté b est exactement le niveau θ auquel la probabilité de réussite est 50%.

3.7 Comment Estimer les Paramètres IRT en Pratique

Estimation par Maximum de Vraisemblance Marginale (MMLE)

Pour estimer a_j, b_j, c_j pour chaque question à partir des réponses de N élèves :

1. **Données requises** : Matrice de réponses R de taille $N \times J$ (N élèves, J questions) ; chaque cellule vaut 1 (correct) ou 0 (incorrect)
2. **Outils** : Bibliothèque mirt (R) ou py-irt (Python)
3. **Volume minimum** : 200-300 élèves par question pour une calibration fiable
4. **Processus** : L'algorithme EM (Expectation-Maximization) optimise les paramètres en maximisant la probabilité d'observer les données

Pour ExamBoost : Dans la phase pilote (300-500 élèves), on collecte les données de réponses et on calibre les paramètres IRT. Avant le pilote, on utilise des valeurs par défaut : $a = 1$, b estimé à partir du taux de réussite historique dans les annales, $c = 0$ pour les questions ouvertes et $c = 1/(\text{nombre de choix})$ pour les QCM.

4 Module 4 — Traçage de la Connaissance : Le Modèle BKT

4.1 Motivation : Pourquoi IRT ne suffit pas

L'IRT mesure le niveau θ d'un élève à un instant donné. Mais pour un système adaptatif, on a besoin de savoir : **l'élève maîtrise-t-il une compétence spécifique à ce stade de son apprentissage ?** Et cette estimation doit être **mise à jour** à chaque réponse. C'est le rôle du BKT.

4.2 Définition et Paramètres du BKT

Bayesian Knowledge Tracing (BKT)

Le BKT est un modèle probabiliste fondé sur un **Modèle de Markov Caché** (HMM). Il estime dynamiquement la probabilité que l'élève maîtrise une compétence donnée, en se mettant à jour après chaque tentative.

Le modèle BKT standard possède **quatre paramètres** par compétence :

Paramètre	Signification	Notation	Valeur typique
Connaissance initiale	Proba que l'élève maîtrise la compétence dès le départ	$P(L_0)$	0,05 à 0,30
Apprentissage	Proba de passer de «non maîtrisé» à «maîtrisé» après une opportunité	$P(T)$	0,10 à 0,40
Erreur (slip)	Proba de faire une erreur même en maîtrisant la compétence	$P(S)$	0,05 à 0,20
Chance (guess)	Proba de répondre juste sans maîtriser la compétence	$P(G)$	0,10 à 0,35

4.3 Les Équations de Mise à Jour du BKT

Le modèle BKT fonctionne en deux étapes après chaque réponse de l'élève.

Étape 1 — Mise à jour a posteriori (après observation d'une réponse) :

BKT — Mise à jour après une réponse correcte ($obs = 1$)

$$P(L_n | obs = 1) = \frac{P(L_{n-1}) \cdot (1 - P(S))}{P(C_n)} \quad \text{où} \quad P(C_n) = P(L_{n-1})(1 - P(S)) + (1 - P(L_{n-1})) \cdot P(G)$$

BKT — Mise à jour après une réponse incorrecte ($obs = 0$)

$$P(L_n | obs = 0) = \frac{P(L_{n-1}) \cdot P(S)}{1 - P(C_n)} \quad \text{où} \quad 1 - P(C_n) = P(L_{n-1}) \cdot P(S) + (1 - P(L_{n-1})) \cdot (1 - P(G))$$

Étape 2 — Projection vers la prochaine opportunité :

BKT — Transition vers la prochaine étape

$$P(L_{n+1}) = P(L_n | obs) + (1 - P(L_n | obs)) \cdot P(T)$$

Cette formule dit : la probabilité de maîtrise après l'opportunité $n + 1$ est la probabilité déjà maîtrisée *plus* la probabilité de maîtriser grâce à cette opportunité d'apprentissage.

4.4 Exemple Numérique Complet — BKT

Compétence : «Résoudre une équation du premier degré à une inconnue» (BEPC Maths)

Paramètres calibrés : $P(L_0) = 0,20$, $P(T) = 0,30$, $P(S) = 0,10$, $P(G) = 0,20$

Séquence de réponses de l'élève : Correcte, Incorrecte, Correcte, Correcte

Initialisation : $P(L_0) = 0,20$

Opportunité 1 — Réponse correcte :

$$P(C_1) = 0,20 \times 0,90 + 0,80 \times 0,20 = 0,18 + 0,16 = 0,34$$

$$P(L_1 | obs = 1) = \frac{0,20 \times 0,90}{0,34} = \frac{0,18}{0,34} \approx 0,529$$

$$P(L_1) = 0,529 + (1 - 0,529) \times 0,30 = 0,529 + 0,141 = \mathbf{0,670}$$

Opportunité 2 — Réponse incorrecte :

$$1 - P(C_2) = 0,670 \times 0,10 + 0,330 \times 0,80 = 0,067 + 0,264 = 0,331$$

$$P(L_2 | obs = 0) = \frac{0,670 \times 0,10}{0,331} = \frac{0,067}{0,331} \approx 0,202$$

$$P(L_2) = 0,202 + 0,798 \times 0,30 = 0,202 + 0,239 = \mathbf{0,441}$$

Opportunité	Réponse	$P(L)$ avant	$P(L)$ après mise à jour
1	Correcte	0,200	0,670 (+34 pts)
2	Incorrecte	0,670	0,441 (−23 pts)
3	Correcte	0,441	0,744 (+30 pts)
4	Correcte	0,744	0,886 (+14 pts)

Seuil de maîtrise : ExamBoost considère qu'une compétence est maîtrisée quand $P(L) \geq 0,85$. A l'opportunité 4, $P(L) = 0,886 > 0,85$: la compétence est déclarée maîtrisée pour cet élève.

Exercice 4.1 — Simulation BKT complète

Pour la compétence «Identifier une figure de style dans un texte» (Français, BEPC) : $P(L_0) = 0,15$, $P(T) = 0,25$, $P(S) = 0,08$, $P(G) = 0,15$. L'élève donne les réponses : Incorrecte, Incorrecte, Correcte.

- Calculer $P(L)$ après chaque opportunité.
- Combien d'opportunités supplémentaires seront-elles nécessaires (en supposant toutes des réponses correctes) pour que $P(L) \geq 0,85$?

Correction de l'Exercice 4.1

Opp. 1 — Incorrecte : $1 - P(C_1) = 0,15 \times 0,08 + 0,85 \times 0,85 = 0,012 + 0,7225 = 0,7345$; $P(L_1 | obs = 0) = (0,15 \times 0,08) / 0,7345 = 0,0163$; $P(L_1) = 0,0163 + 0,9837 \times 0,25 = \mathbf{0,263}$

Opp. 2 — Incorrecte : $1 - P(C_2) = 0,263 \times 0,08 + 0,737 \times 0,85 = 0,021 + 0,626 = 0,647$; $P(L_2 | obs = 0) = (0,263 \times 0,08) / 0,647 = 0,032$; $P(L_2) = 0,032 + 0,968 \times 0,25 = \mathbf{0,274}$

Opp. 3 — Correcte : $P(C_3) = 0,274 \times 0,92 + 0,726 \times 0,15 = 0,252 + 0,109 = 0,361$; $P(L_3 | obs = 1) = (0,274 \times 0,92) / 0,361 = 0,698$; $P(L_3) = 0,698 + 0,302 \times 0,25 = \mathbf{0,773}$

b) A partir de $P(L_3) = 0,773$, une réponse correcte : $P(C_4) = 0,773 \times 0,92 = 0,711$; $P(L_4 | obs = 1) = 0,711 / 0,711 \times (0,773 / 0,773) \dots$ On itère : $P(L_4) \approx 0,773 + (0,773 \times 0,92) / (P(C)) \times (1 - \dots)$. En poursuivant le calcul : après 1 correcte supplémentaire : $P(L) \approx 0,896 > 0,85$. **Il suffit d'une seule réponse correcte supplémentaire** pour déclarer la maîtrise.

5 Module 5 — Modèles ML : Inventaire, Rôles et Entraînement

5.1 Vue d'Ensemble des Modèles ML du Projet

ExamBoost Togo utilise **cinq familles de modèles ML**, chacune avec un rôle précis :

Modèle	Rôle dans ExamBoost	Entrée / Sortie
IRT (3PL/2PL)	Calibrer chaque question	Réponses élèves $\rightarrow a, b, c$
SM-2 / FSRS	Planifier les révisions	Historique réponses $\rightarrow$ prochain rappel
BKT	Tracer la maîtrise / compétence	Séquence réponses $\rightarrow P(L)$
XGBoost / RF	Prédire le score à l'examen	Profil élève $\rightarrow$ score estimé
Régression LASSO	Identifier les facteurs clés	Features $\rightarrow$ score final

5.2 Modèle 1 — IRT : Calibration des Questions

5.2.1 Rôle dans ExamBoost

Chaque question de la banque de données ExamBoost doit avoir ses paramètres a, b, c estimés. Ces paramètres permettent de sélectionner la bonne question pour chaque élève : une question avec $b \approx \theta_{lve}$ est optimale (ni trop facile, ni trop difficile).

5.2.2 Données nécessaires

- Matrice de réponses $R \in \{0, 1\}^{N \times J}$: au moins 200 élèves par question
- Identifiant unique par élève et par question
- Temps de réponse (optionnel mais utile pour détecter la chance)

5.2.3 Procédure d'entraînement

1. **Phase 0 (avant pilote)** : Valeurs par défaut : $a = 1$, $c = 0$ (ou $1/k$ pour QCM à k choix), b estimé par $b = \Phi^{-1}(1 - p_{hist})$ où p_{hist} est le taux de réussite

historique dans les annales et Φ^{-1} est le quantile de la normale standard.

2. **Phase 1 (pilote 300-500 élèves)** : Estimation MMLE avec `py-irt` (Python) ou `mirt` (R). Critère de convergence : log-vraisemblance.
3. **Phase 2 (production)** : Re-calibration mensuelle avec les nouvelles données. Retirer les questions avec $a < 0,3$ (peu discriminantes) ou $c > 0,4$ (trop de chance).

5.2.4 Choix du modèle : 1PL, 2PL ou 3PL ?

Modèle	Avantage	Inconvénient	Recommanda
1PL (Rasch)	Simple, robuste avec peu de données	Ignore la discrimination	Démarrage ($N < 200$)
2PL	Bon équilibre précision/données	Nécessite 300+ élèves	Phase pilote
3PL	Gère le hasard dans les QCM	Nécessite 500+ élèves	Production (QCM)

Décision ExamBoost : Démarrer en 1PL, migrer vers 2PL au pilote, puis 3PL en production pour les QCM uniquement.

5.3 Modèle 2 — BKT : Traçage de la Maîtrise

5.3.1 Rôle dans ExamBoost

Pour chaque élève et chaque compétence du programme MEPST, le BKT maintient une probabilité de maîtrise $P(L)$ qui se met à jour en temps réel. Cette probabilité pilote :

- La sélection des prochaines questions (compétences non encore maîtrisées en priorité)
- Le tableau de bord de l'élève (carte de chaleur des compétences)
- Les alertes envoyées aux enseignants (élèves bloqués sur une compétence)

5.3.2 Entraînement du BKT

Outils : `pyBKT` (Python, open-source, Berkeley) ou package R BKT.

Données : Triplets $(\text{eleve_id}, \text{competence_id}, \text{reponse} \in \{0, 1\})$ ordonnés chronologiquement.

Algorithme : Expectation-Maximization (EM) sur les séquences de réponses.

Évaluation : AUC-ROC sur un ensemble de test ($\sim 20\%$ des données).

Fréquence de ré-entraînement : Mensuel au lancement, puis trimestriel en production.

5.3.3 Variante : Deep Knowledge Tracing (DKT)

Pour les utilisateurs avancés : le DKT remplace la chaîne de Markov par un réseau de neurones récurrent (LSTM). Il capture des dépendances entre compétences mais nécessite plus de données et est moins interprétable.

Modèle	Données min.	Interprétabilité	Précision
BKT standard	500 séquences	Très haute	Bonne (AUC 0,70-0,75)
BKT étendu (IRT)	1 000 séquences	Haute	Très bonne (AUC 0,75-0,80)
DKT (LSTM)	10 000 séquences	Faible	Excellente (AUC 0,80-0,85)

Décision ExamBoost : BKT standard au lancement, DKT en phase 3 (> 10 000 utilisateurs).

5.4 Modèle 3 — Prédiction du Score à l'Examen

5.4.1 Rôle dans ExamBoost

L'application affiche à l'élève un **score prédit** pour son prochain examen (BEPC ou BAC) sous forme d'un indicateur de préparation. Cela motive les élèves à pratiquer régulièrement.

5.4.2 Features (variables d'entrée)

Feature	Description
$P(L)$ par matière	Probabilité de maîtrise agrégée par matière (BKT)
Score aux simulations	Moyenne des 3 dernières simulations d'examen
Régularité	Nombre de sessions/semaine sur les 4 dernières semaines
Temps moyen/question	Indicateur de fluence (réponse rapide = bonne maîtrise)
Taux d'achèvement	% du programme couvert dans les révisions
θ IRT estimé	Niveau de compétence global estimé par IRT

5.4.3 Algorithmes candidats

Option A — Régression Ridge/LASSO :

$$\hat{y} = \beta_0 + \sum_{k=1}^K \beta_k x_k \quad \text{avec pénalité :} \quad \min_{\beta} \left[\sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_k |\beta_k| \right]$$

Avantage : simple, interprétable, LASSO sélectionne automatiquement les features importantes. Inconvénient : ne capture pas les interactions non linéaires.

Option B — XGBoost (Gradient Boosting) : Ensemble de 100 à 500 arbres de décision entraînés séquentiellement. Chaque arbre corrige les erreurs du précédent.

Algorithme	Données min.	RMSE typique	Recommandation
Ridge/LASSO	200 élèves	3-4 pts	Phase pilote (peu de données)
XGBoost	1 000 élèves	1,5-2,5 pts	Production
Random Forest	500 élèves	2-3 pts	Alternative à XGBoost

Décision ExamBoost : Ridge au pilote, XGBoost en production. Validation croisée 5-fold systématique. Métrique principale : RMSE (Root Mean Squared Error) sur les notes /20.

5.4.4 Entraînement du modèle de prédiction

1. **Collecte des données** : Après le premier examen national (BEPC 2026), comparer les prédictions aux notes réelles pour calibrer le modèle.
2. **Feature engineering** : Normalisation des features, création d'interactions (ex : $P(L_{\text{Maths}}) \times P(L_{\text{Physique}})$ pour la série C).
3. **Entraînement** : Diviser en 80% entraînement / 20% test. Hyperparameter tuning via GridSearchCV.
4. **Déploiement** : Modèle sérialisé (joblib) et appelé depuis l'API FastAPI.

5.5 Modèle 4 — Détection des Élèves à Risque de Décrochage

Ce modèle est destiné au tableau de bord des enseignants et directeurs d'établissement.

Cible (variable à prédire) : L'élève décroche dans les 30 prochains jours (absence de connexion + note en chute).

Features : Nombre de sessions sur les 7 derniers jours, variation du score de simulation, nombre de jours sans connexion, $P(L)$ moyen en baisse.

Algorithme : Classification binaire avec **Logistic Regression** (interprétable) ou **Random Forest** (plus précis).

Métrique : Rappel (recall) $\geq 80\%$ sur la classe «décrochage» (on préfère avoir des faux positifs plutôt que de rater un vrai décrochage).

Explicabilité : Utiliser SHAP (SHapley Additive exPlanations) pour montrer à l'enseignant *pourquoi* l'élève est en risque («il n'a pas utilisé l'app depuis 8 jours et son score en Maths a baissé de 4 points»).

5.6 Récapitulatif : Modèles, Données et Performances Attendues

Modèle	Phase	Données min.	Métrique cible	Outil
IRT 1PL	Lancement	100 réponses/q.	AIC/BIC	py-irt / mirt
IRT 2PL/3PL	Pilote	300–500 élèves	RMSE < 0,15	py-irt / mirt
SM-2 / FSRS	Lancement	0 (règles)	Rétention > 85%	Dart (Flutter)
BKT standard	Pilote	500 séquences	AUC > 0,72	pyBKT
XGBoost score	Production	1 000 élèves	RMSE < 2 pts/20	scikit-learn
Décrochage RF	Production	500 élèves	Recall > 80%	scikit-learn + SHAP

6 Module 6 — Stratégie Complète de Collecte des Données

6.1 Vue d'Ensemble : Les Trois Couches de Données

La stratégie de données d'ExamBoost Togo est organisée en trois couches selon leur disponibilité :

Couche	Type	Source	Action
1	Données pédagogiques historiques	Annales, sujets officiels	Scraping + OCR
2	Données de programme	Curricula MEPST	Partenariat officiel
3	Données comportementales	Réponses des élèves dans l'app	Collection in-app

6.2 Couche 1 : Données Pédagogiques Disponibles en Ligne

6.2.1 Sources identifiées pour le BEPC, BAC 1 et BAC 2 (Togo)

Site / Source	Années	Format	Contenu
epreuvesetcorriges.co	2010-2025	PDF	BEPC, BAC Togo (toutes séries et matières)
banquedesepreuves.ci	2015-2024	PDF	BEPC + BAC Togo, Bénin, Côte d'Ivoire
examens-concours.net	2015-2025	PDF	Togo : BAC Maths série C (jusqu'en 2025)
fomesoutra.com	2016-2024	PDF	Sujets et corrigés BEPC Togo
digischool.fr (Afrique)	2012-2022	PDF	BAC francophone Afrique de l'Ouest
mathsenligne-afrique.com	2014-2023	PDF/HTML	Exercices maths lycée francophone

Site / Source	Années	Format	Contenu
lewebpedagogique.com	2010–2022	PDF	Ressources pédagogiques lycée français
cours-gratuit.com	2008–2022	PDF	Cours et exercices lycée + BAC Afrique
MEPST (portail officiel)	Variable	PDF officiel	À négocier pour accès complet
internet archive (archive.org)	Depuis 1995	HTML/PDF	Archives de sites éducatifs togolais
YouTube (chaînes togolaises)	2018–2025	Vidéo	Cours filmés : transcription possible
Groupe WhatsApp scolaires	2019–2025	PDF/Image	Sujets d'examens blancs partagés informellement

6.2.2 Couverture par Matière : Inventaire Estimé

Matière	Examen	Sujets disponibles (estimé)	Corrigés disponibles	Priorité
Mathématiques	BEPC + BAC	80-120 sujets	60%	Critique
Français	BEPC + BAC	80-100 sujets	50%	Critique
Sciences Phys.	BAC C	50-70 sujets	55%	Haute
SVT (Biologie)	BAC D	50-70 sujets	50%	Haute
Histoire-Géo	BEPC + BAC A/B	60-80 sujets	40%	Moyenne
Anglais	BEPC + BAC	40-60 sujets	35%	Moyenne
Philosophie	BAC (toutes séries)	40-60 sujets	30%	Moyenne
Économie	BAC B	30-50 sujets	25%	Faible
Physique-Chimie	BEPC	40-60 sujets	40%	Haute
Éducation Civique	BEPC	20-30 sujets	20%	Faible

6.3 Processus de Numérisation : Du PDF au QCM Structuré

Pipeline OCR et Structuration des Données

Étape 1 — Acquisition : Téléchargement systématique des PDF depuis les sites identifiés. Script Python avec requests + BeautifulSoup pour le scraping. Résultat : environ 800-1 200 fichiers PDF organisés par (examen / année / matière / série).

Étape 2 — OCR : Conversion PDF → texte avec Tesseract (français) ou GPT-4o Vision pour les formules mathématiques et chimiques (plus précis). Estimation : 15-30 secondes par page. Pour 1 500 pages : en-

viron 10-12 heures de traitement.

Étape 3 — Segmentation : Découpage automatique du texte en (numéro de question / énoncé / points / réponse officielle si disponible). Utilisation de règles heuristiques + LLM pour les cas ambigus.

Étape 4 — Annotation humaine : Chaque question est vérifiée et annotée par un opérateur : (matière / chapitre du programme / type de question / niveau de difficulté estimé). Volume : 3 000-6 000 questions. Temps : 3 mois avec 3 opérateurs à mi-temps.

Étape 5 — Validation pédagogique : Deux enseignants experts (un par matière prioritaire) vérifient la correction des réponses et la pertinence des annotations.

6.3.1 Structure de la Base de Données Questions

Chaque entrée de la base de données a le format suivant :

Listing 1 : Schéma d'une question dans la base de données ExamBoost

```

1 {
2   "question_id": "TG-BEPC-MATHS-2019-Q03",
3   "source": {
4     "examen": "BEPC",
5     "annee": 2019,
6     "pays": "Togo",
7     "serie": null,          # null pour BEPC (pas de série)
8     "numero": 3
9   },
10  "contenu": {
11    "enonce": "Calculer la valeur de x dans l'équation  $3x + 7 = 22$ .",
12    "type": "ouvert",      # ou "qcm" ou "redaction"
13    "choix": null,         # liste de choix si QCM
14    "reponse_correcte": "x = 5",
15    "points": 4
16  },
17  "pedagogie": {
18    "matiere": "Mathematiques",
19    "chapitre": "Equations du premier degre",
20    "competence_id": "MATHS-EQ1D-001",
21    "niveau_estime": 0.6   # b_j initial (avant calibrage IRT)
22  },
23  "irt": {
24    "a": null,             # a remplir après calibrage
25    "b": null,
26    "c": null,
27    "calibre": false
28  }
29 }
```

6.4 Couche 2 : Données du Programme MEPST

6.4.1 Contenu à obtenir

- Liste officielle des chapitres et compétences par matière et par niveau (3^{ème}, 1^{ère}, Terminale) — c'est la **carte des compétences** qui structure le BKT
- Barèmes officiels par matière et coefficient par examen et série
- Référentiel des examens : durée, format, instructions spécifiques

6.4.2 Stratégie d'accès

1. **Demande officielle au MEPST** : Lettre formelle de demande de partenariat. Argument : l'application bénéficie directement aux élèves togolais et soutient les objectifs du Ministère.
2. **Reconstruction par ingénierie inverse** : En l'absence de réponse rapide, extraire la structure du programme à partir des annales elles-mêmes : les questions des 10 dernières années couvrent l'essentiel du curriculum.
3. **Sources alternatives** : Manuel scolaire officiel togolais (disponibles partiellement en ligne) ; programmes de pays voisins (Bénin, Côte d'Ivoire) dont le curriculum est très proche.

6.5 Couche 3 : Données à Produire — Les Examens Blancs

6.5.1 Pourquoi les examens blancs sont critiques

Les annales officielles couvrent les sujets passés. Mais pour entraîner les modèles ML et offrir de la variété aux élèves, ExamBoost Togo a besoin de **nouvelles questions inédites**, calibrées sur le programme et dans le même style que les sujets officiels.

6.5.2 Stratégie de génération de nouvelles questions

1. **Génération par LLM guidé** : Utiliser GPT-4o ou Mistral fine-tuné sur les annales togolaises pour générer de nouvelles questions dans le style officiel. Prompt type : «Génère 3 questions de mathématiques de niveau BEPC Togo, chapitre équations du premier degré, style des années 2015-2023, avec corrigés détaillés.»
2. **Validation humaine obligatoire** : Tout contenu généré par IA doit être validé par un enseignant avant publication dans l'app. **Une question incorrecte publiée peut détruire la confiance des utilisateurs.**
3. **Partenariat avec les lycées pour les examens blancs** : Solliciter les directeurs d'établissements pour partager les sujets d'examens internes

(avec leur accord : anonymisation des origines).

6.5.3 Stratégie de collecte des données comportementales in-app

Ces données sont les plus précieuses car elles permettent de calibrer les modèles ML :

Donnée collectée	Utilisation	Fréquence de collecte
Réponse à chaque question (0/1)	Calibrage IRT, mise à jour BKT	En temps réel
Temps de réponse (secondes)	Paramètre de fluence pour XGBoost	En temps réel
Séquence de sessions	Calcul SRS, rétention	Par session
Score aux simulations complètes	Entraînement modèle prédictif	Après chaque simulation
Notes réelles aux examens officiels	Validation du modèle prédictif	Post-examen (saisie manuelle)

Protection des données : Conformité avec la loi togolaise sur la protection des données personnelles. Anonymisation systématique pour l'entraînement des modèles. Consentement explicite demandé à l'inscription.

6.6 Plan de Collecte : Calendrier et Responsabilités


Mois	Activité	Livrable	Responsable
M1–M2	Scraping sites + téléchargement PDFs	1 200 PDFs organisés	Dev Python
M2–M3	OCR + segmentation automatique	3 000 questions brutes	Dev + Data Eng.
M3–M4	Annotation manuelle (matière / chapitre)	3 000 questions annotées	Opérateurs
M4–M5	Validation pédagogique	2 500 questions validées	Enseignants experts
M5–M6	Pilote in-app (300 élèves)	Données IRT initiales	Équipe complète
M6–M7	Calibrage IRT + BKT	Paramètres $a, b, c, P(L)$	Data Scientist
M7–M8	1 ^{er} entraînement modèle prédictif	Modèle XGBoost v1	Data Scientist

Conclusion — Synthèse des Connaissances

Ce cours a couvert l'ensemble des fondements théoriques nécessaires pour construire ExamBoost Togo. Voici le récapitulatif des liens entre les modules :

Comment les modules s'articulent dans ExamBoost

1. **Module 1 (Courbe d'oubli)** : Justifie *pourquoi* il faut un SRS. Sans répétition espacée, les élèves oublient 90% de ce qu'ils ont appris en une semaine.
2. **Module 2 (SM-2)** : Donne *quand* réviser. L'algorithme SM-2 planifie chaque révision au moment optimal, maximisant la rétention à long terme.
3. **Module 3 (IRT)** : Donne *quelle question* proposer. La sélection adaptative choisit une question dont la difficulté b correspond au niveau θ de l'élève : ni trop facile (ennui), ni trop difficile (découragement).
4. **Module 4 (BKT)** : Répond à *à quel niveau de maîtrise* est l'élève sur chaque compétence. Il pilote le tableau de bord et les alertes enseignant.
5. **Module 5 (ML)** : Permet de *prédire* le score final à l'examen et de détecter les élèves à risque de décrochage.
6. **Module 6 (Données)** : Fournit le carburant de tous les modèles : sans données de qualité, aucun algorithme ne peut être performant.



Fin du Cours

Équipe SmartFarm Togo / AIMS Ghana — Mai 2025